Syntax natürlicher Sprachen

12: Partielles Parsing

A. Wisiorek

Centrum für Informations- und Sprachverarbeitung,
Ludwig-Maximilians-Universität München

20.01.2026

Themen der heutigen Vorlesung

1. Partielles Parsing (Chunking)

2. Chunking mit regulärer Grammatik
   - RegExp-Chunk-Parser
   - Kaskadierende Chunker
   - Evaluation von Chunkern

3. Lernbasierte Chunking-Modelle (IOB-Tagger)

1. Partielles Parsing (Chunking)

Partielle/flache vs. vollständige/hierarchische Analyse

- für viele Anwendungen: **keine syntaktische Vollanalyse notwendig**
- **Partielles Parsing** als **unvollständige, flache Syntaxanalyse**
  $\rightarrow$ *nur die Konstituententypen mit* ***Inhaltswort als Kopf:***
  `NP, VP, PP, AdjP`
  $\rightarrow$ *auch als* ***Chunking*** *bezeichnet (Abney 1991: 'parsing by chunks')*
- Partielle-Parsing-Methoden u.a. entwickelt für:
  - **Informationsextraktion**: Finden semantischer Einheiten
  - ***Information Retrieval***: Phrasen als Indexterme

Partielle Analyse

- **unvollständige Analyse**: nur die Wörter berücksichtigt, die **Element der relevanten syntaktischen Einheiten** sind
- **andere Wörter** werden **nicht syntaktisch annotiert**

  $\Rightarrow$ **Partielle syntaktische Analyse**
- z. B. nur NP-Chunks:

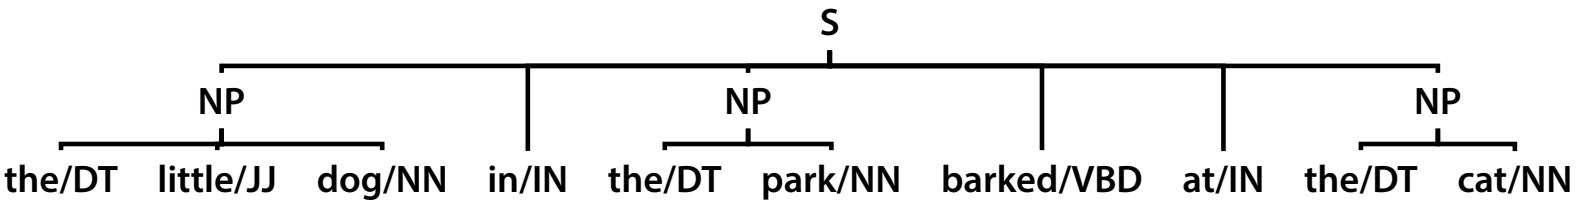

Flache Analyse

- flache, **nicht-hierarchische syntaktische Analyse**
  → *Chunk-Bäume haben* ***Tiefe 1***
  → ***keine komplexen****, verschachtelten* ***Phrasen***
- **Chunk als *base phrase*:**
  → ***kleinere Einheiten als vollständige Phrasen***
  → *NP-Chunks* ***ohne Rechtsattribute***
  → *PP-***Chunks** *bestehen* ***nur aus Präposition***:

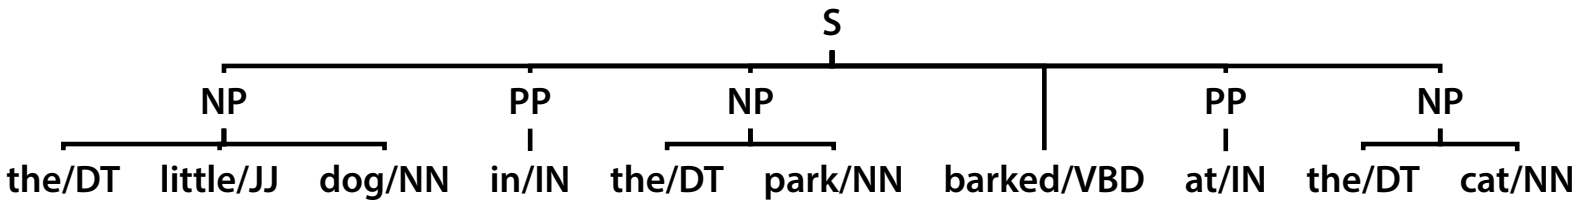

2 Aufgaben für Chunk-Parser

1. ***Segmentierung*** = **Grenzen** der Chunks **finden**
   → *Identifizierung von* ***Sequenzen von Tokens*** *als Chunks*
2. ***Labeling*** der Chunks
   → ***Klassifikation*** *der Einheiten* = ***Tagging***

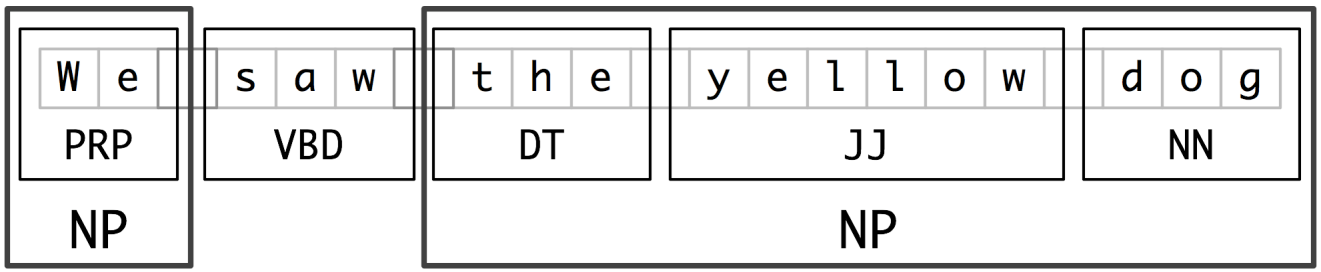

Abbildung: Segmentierung und Labeling auf Token- und Chunk-Ebene (http://www.nltk.org/images/chunk-segmentation.png)

2 Methoden zur Erstellung von Chunk-Parsern

1. **regelbasiert** mit regulärer Grammatik
2. ***supervised machine learning***

- zentrales Merkmal in beiden Ansätzen: **POS-Tags**

Repräsentationsformate für Chunk-Analysen

- **Darstellung** über flache **Bäume**:

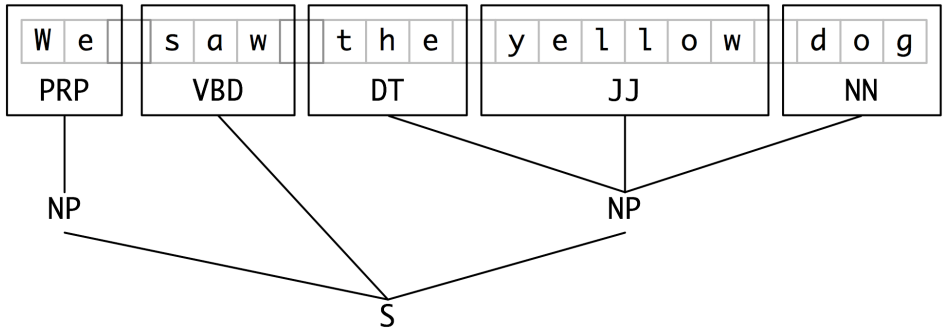

Abbildung: Baum-Repräsentation von Chunks (http://www.nltk.org/images/chunk-treerep.png)

- **Darstellung** über **Tags** (**IOB-Format**):

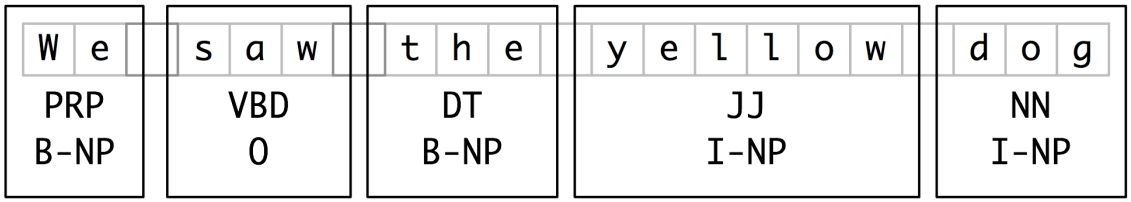

Abbildung: Tag-Repräsentation von Chunks im IOB-Format (http://www.nltk.org/images/chunk-tagrep.png)

Partielles vs. Vollständiges Parsing

Vorteile

- **einfaches Modell**, in vielen Anwendungsfällen ausreichend
- **weniger Disambiguierungsprobleme** als bei PSG-Grammatiken
  $\rightarrow$ *z. B.* ***Vermeidung PP-Attachment-Ambiguität*** *durch nicht-hierarchische Analyse*
- **bessere Performance** gegenüber CFGs oder Unifikationsgrammatiken, z.B. **Chunker als reguläre Grammatik**
- **hohe Accuracy** aufgrund flacher, unvollständiger Strukturanalyse

Nachteile

- nur **unvollständige Beschreibung** syntaktischer Struktur
- **grammatische Beziehungen** in der syntaktischen Struktur **durch die flache Analyse** nicht direkt modelliert
  → ***nur heuristisch erfassbar, z. B.:***
  → *NP vor Verb ist Subjekt oder erste NP ist Subjekt*
  → *Heuristik kann **bei komplexen NPs fehlschlagen**:*

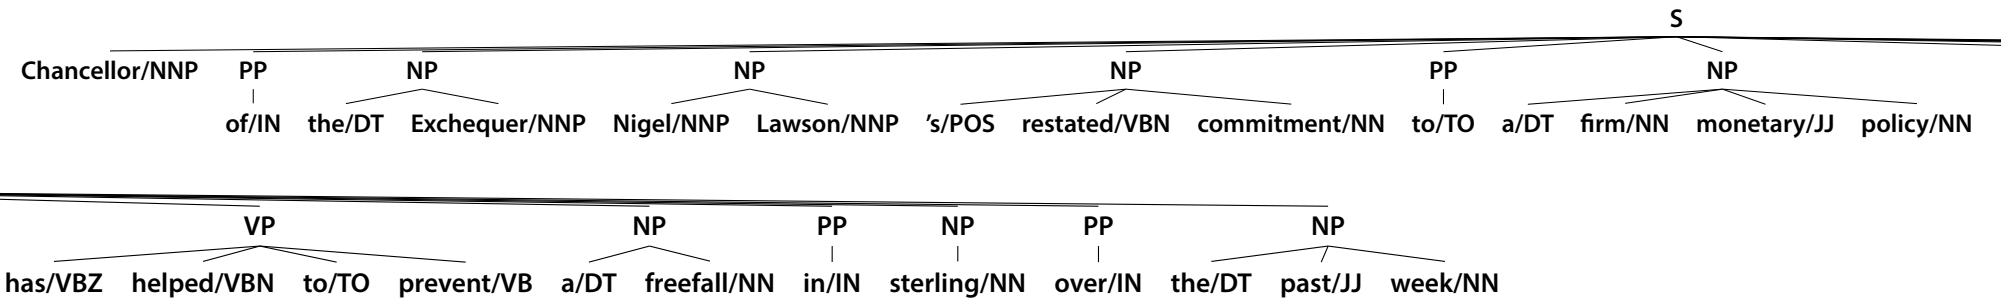

Listing 1: NLTK: Beispiel flach analysierter komplexer NP (aus `conll2000`-Korpus)

```
#(S
#  Chancellor/NNP
#  (PP of/IN)
#  (NP the/DT Exchequer/NNP)
#  (NP Nigel/NNP Lawson/NNP)
#  (NP 's/POS restated/VBN commitment/NN)
#  (PP to/TO)
#  (NP a/DT firm/NN monetary/JJ policy/NN)
#  (VP has/VBZ helped/VBN to/TO prevent/VB)
#  (NP a/DT freefall/NN)
#  (PP in/IN)
#  (NP sterling/NN)
#  (PP over/IN)
#  (NP the/DT past/JJ week/NN)
#  ./.)
```

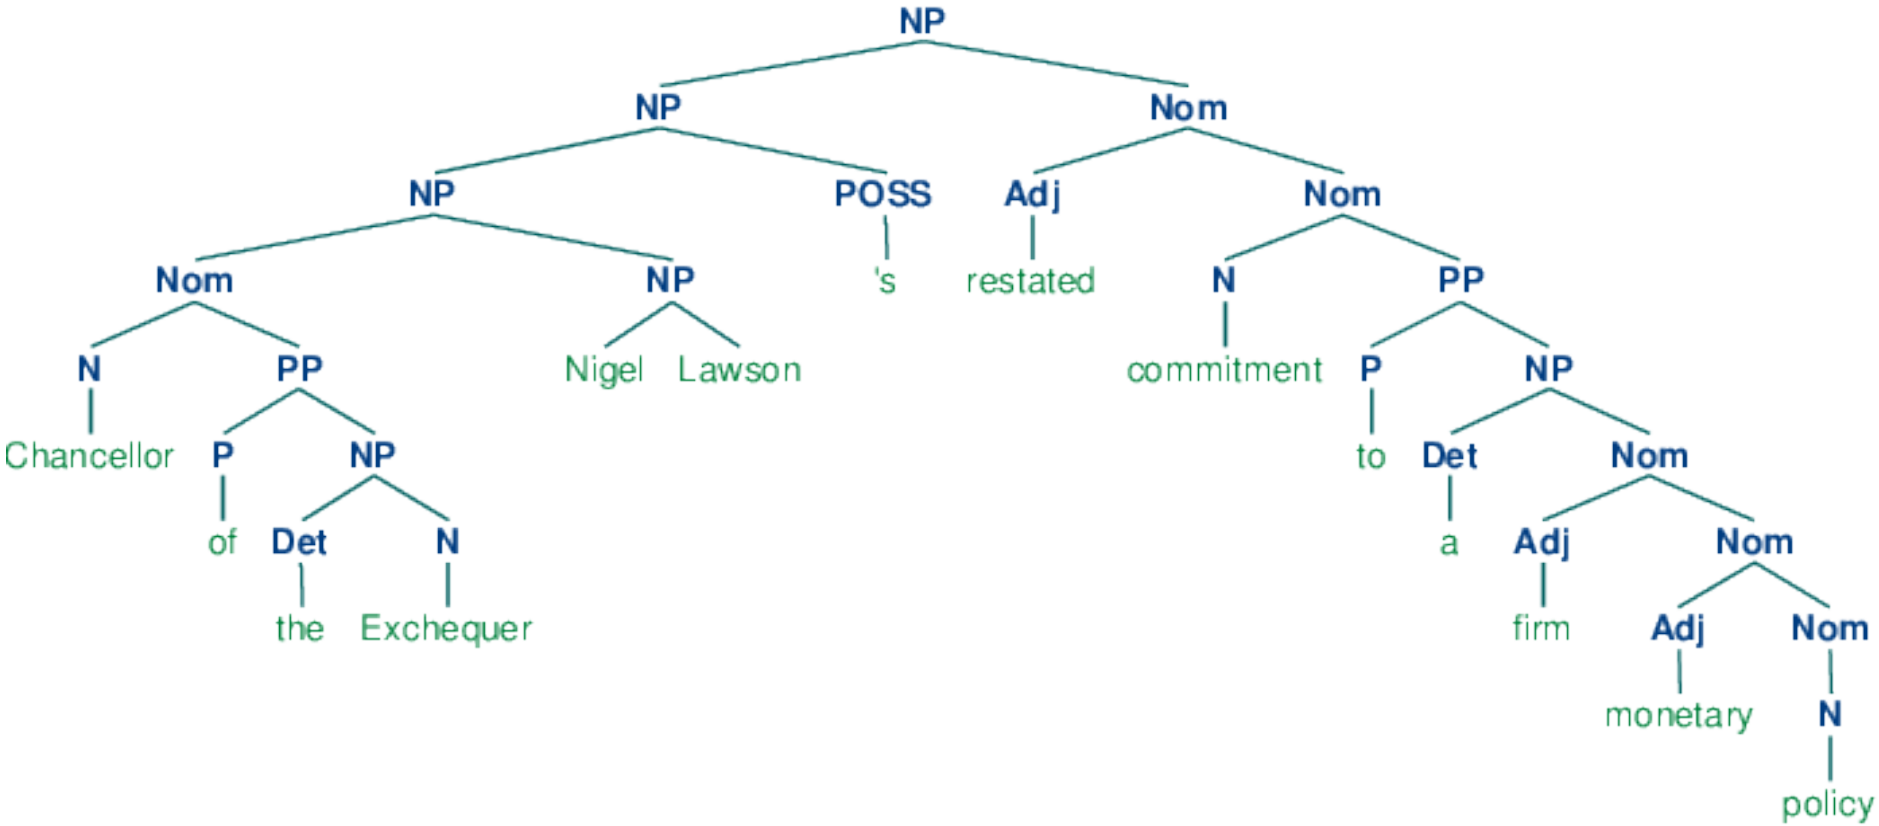

Abbildung: Vollständige Phrasenstrukturanalyse der komplexen Subjekt-NP (http://www.nltk.org/book/tree_images/ch08-extras-tree-1.png)

Strukturpositionen in CFG-Analysen

- in **hierarchischer Phrasenstrukturanalyse** wird die **komplexe NP unter einem NP-Knoten** zusammengefasst (statt in viele NP-Chunks aufgesplittet)
  $\rightarrow$ *komplexe NPs werden **in ihrem hierarchischem Aufbau** analysiert und der **Kopf der Phrase** ist in einem X-Bar-Schema **über Strukturposition** eindeutig **identifizierbar**: NP, NOM+, N*
- **Subjekt- und Objekt-Funktion** sind über **Position im Strukturbaum** repräsentiert
  $\rightarrow$ *Subjekt-NP unmittelbar dominiert von S*
  $\rightarrow$ *Objekt-NP unmittelbar dominiert von VP*

2. Chunking mit regulärer Grammatik

1. Partielles Parsing (Chunking)

2. Chunking mit regulärer Grammatik
   - RegExp-Chunk-Parser
   - Kaskadierende Chunker
   - Evaluation von Chunkern

3. Lernbasierte Chunking-Modelle (IOB-Tagger)

2.1. RegExp-Chunk-Parser

1. Partielles Parsing (Chunking)

2. Chunking mit regulärer Grammatik
   - RegExp-Chunk-Parser
   - Kaskadierende Chunker
   - Evaluation von Chunkern

3. Lernbasierte Chunking-Modelle (IOB-Tagger)

RegExp-Parser

- **Beschreibung von POS-Folgen** durch **reguläre Ausdrücke** (Tag-Pattern)
- **Tag-Muster** = Regeln einer **Chunk-Grammatik**
  → ***NLTK-eigene Syntax**: POS-Tags in **eckigen Klammern**:*
  → *z. B. Chunk als POS-Folge Artikel - Adjektivattribute (optional) - Nomen:*
  `<DT><JJ>*<NN>`
- Chunking als **sukzessive Anwendung der Regeln** einer Chunk-Grammatik auf die Sätze eines POS-getaggten Textes
- **FSTs = *finite state transducers*** ermöglichen **Segmentierung und Labeling** (Output durch *transducer*): `NP: <DT><JJ>*<NN>`

Reihenfolge der Regeln

- **bereits gefundene Chunk-Elemente:** in folgenden Regeln **nicht mehr verfügbar**
  → *nur **nicht-überlappende Chunks** werden gefunden*
  → ***Reihenfolge der Regeln** in Grammatik ist also **wichtig***
  → *z.B. wird bei invertierter Regel-Abfolge wird die `POSS-ADJ-NN`-Folge nicht gefunden, wenn `NN` schon als NP erkannt*
- **Tracing** hilfreich beim **Entwickeln von Chunk-Grammatiken**
  → *Beschreibung der Regeln durch **Kommentare***

Chunking und Chinking

- **Chunking-Regel:** Definition Chunk als Muster einer POS-Folge:
  → *NP: {<NNP>+}*
- **Chinking-Regel:** Definition eines Musters einer POS-Folge, die **nicht in Chunk enthalten** ist:
  → *}<VBD|IN>+{*

  `[ the/DT little/JJ yellow/JJ dog/NN ] barked/VBD at/IN [ the/DT cat/NN ]`

  → ***Anwendung auf bereits gefundene Chunks***
- **Möglichkeiten beim Chinking:**
  - wenn Chink-Muster in **Mitte** von Chunk
    ⇒ Chunk wird entsprechend **gesplittet**
  - wenn Chink-Muster **kompletter Chunk**
    ⇒ Chunk wird **entfernt**
  - wenn Chink-Muster am **Anfang oder Ende** von Chunk
    ⇒ Chunk wird entsprechend **beschnitten**

Split-Regeln

- **Split-Regeln**
  → ***Anwendung auf gefundene Chunks***
  → *z. B.* ***Splitten*** *von gefundener* ***NP am Determinierer:***
  → `<.*>}{<DT>`

2.2. Kaskadierende Chunker

1. Partielles Parsing (Chunking)

2. Chunking mit regulärer Grammatik
   - RegExp-Chunk-Parser
   - Kaskadierende Chunker
   - Evaluation von Chunkern

3. Lernbasierte Chunking-Modelle (IOB-Tagger)

Kaskadierende Chunk-Parser

- durch **Kombination** von (flachen) **Chunk-Parsern** können **hierarchische, tiefere Strukturen** erzeugt werden
  → ***Output eines Chunkers*** *dient als* ***Input des Folgenden***
  → *Regeln können* ***Chunk-Tags enthalten****:*
  ⇒ *hierarchische Strukturen, z. B.* `PP: {<IN><NP>}`)
  → ***Approximation*** *Output eines* ***PSG-Parsers***
- **Loopen eines Chunk-Parsers** über von diesem Parser erkannte Muster:
  → *findet* ***Chunks, die in einem ersten Durchlauf nicht erkannt*** *wurden*

Beispiel: hintereinandergeschaltete Chunk-Parser für komplexe PPs

1. Suche **Adjektivattribute (AdjP)**: `<JJ>+`
2. Suche **NPs**: `<DT><ADJP><NN>`
3. Suche **PPs**: `<P><NP>`

Satz		on/IN		the/DT		black/JJ		mat/NN	
Chunker 1		on/IN		the/DT	[ADJP	black/JJ	]	mat/NN	
Chunker 2		on/IN	[NP	the/DT	[ADJP	black/JJ	]	mat/NN	]
Chunker 3	[PP	on/IN	[NP	the/DT	[ADJP	black/JJ	]	mat/NN	]]

Abbildung: Beispiel kaskadierender Chunk-Parser zur Analyse einer komplexen PP

Beispiel: Looping für Analyse eingebetteter Objektsätze

- Beispiel: in Objektsatz eingebetteter Objektsatz:
  - *John thinks Mary saw the cat sit on the mat*
- Regeln müssen zwei Mal angewendet werden, um die zweifache Clause-Einbettung zu erkennen

2.3. Evaluation von Chunkern

1. Partielles Parsing (Chunking)
2. Chunking mit regulärer Grammatik
   - RegExp-Chunk-Parser
   - Kaskadierende Chunker
   - Evaluation von Chunkern
3. Lernbasierte Chunking-Modelle (IOB-Tagger)

Chunk-Korpus für Evaluation

- `conll2000`-**Korpus** im NLTK (270.000 Tokens)
  $\rightarrow$ ***POS- und Chunk-getaggtes Korpus mit NPs, VPs, und PPs***
  $\rightarrow$ *Aufteilung in* ***Test- und Trainingsmenge***
- Auswahl **Chunks bestimmter Typen** mit `chunk_types`**-Argument**
- Das Korpus kann zum **Evaluieren von Chunk-Parsern** verwendet werden
- **Vergleich Chunker-Output** (Hypothese) mit Test-Menge als ***gold-standard*-Referenz-Korpus** (annotiert von Experten)

Evaluationsmaße

- **korrekter Chunk = korrekte Spanne und korrektes Label**
- **Recall:** $R = \frac{\text{(Anzahl von korrekten Chunks in Chunker-Output)}}{\text{(Anzahl aller Chunks in Referenz-Korpus)}}$
  $\rightarrow$ *Anteil der Chunks des Referenz-Korpus, die vom Chunker korrekt identifiziert wurden*
- **Precision:** $P = \frac{\text{(Anzahl von korrekten Chunks in Chunker-Output)}}{\text{(Anzahl aller Chunks in Chunker-Output)}}$
  $\rightarrow$ *Anteil der vom Chunker identifizierten Chunks, die korrekt sind*
- **F-score** $= \frac{(\beta^2 + 1)PR}{\beta^2 P + R}$
  $\rightarrow$ *Kombination von Precision und Recall in einem Maß*
  $\rightarrow$ β*: Parameter zur Gewichtung von P und R, gleichgewichtet:*

$$F_1 = \frac{2PR}{P + R}$$ *(harmonisches Mittel von P und R)*

3. Lernbasierte Chunking-Modelle (IOB-Tagger)

Chunk-Parsing mit IOB-Tags

- **Training eines Klassifikators**, der die **Wörter auf Chunk-Klassen abbildet**
- Vorgehen **analog zu POS-Tagging** mit ***supervised machine-learning***
  $\rightarrow$ ***POS-Tagging:*** *Abbildung* ***Token auf POS-Tag***
  $\rightarrow$ ***Chunking:*** *Abbildung* ***Token-POS-Tupel auf IOB-Tag (IOB-Tagging)***
  $=$ ***Sequenzklassifikation*** *('parsing as tagging')*
- für **Training** ist ein **Chunk-getaggtes Korpus im IOB-Format** notwendig, z. B. das `conll2000`**-Korpus im NLTK**

IOB-Format

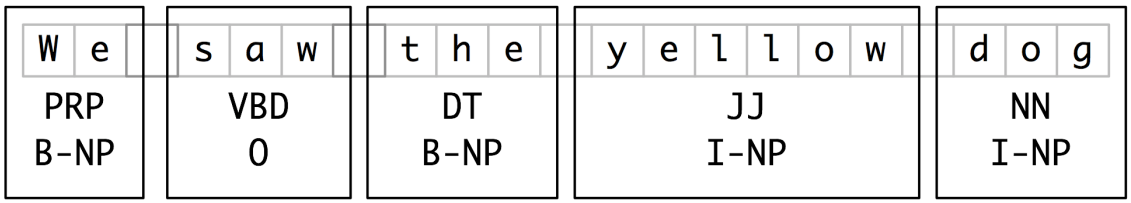

Abbildung: IOB-Tags als Chunk-Tags
(http://www.nltk.org/images/chunk-tagrep.png)

- **IOB = 'Inside–Outside–Beginning'**
- IOB-Tag repräsentiert gleichzeitig **Segmentierung+Label**
- **wortweise** Auszeichnung von **verbundenen Sequenzen**
- **Ende eines Chunks implizit kodiert:**
  $\rightarrow$ ***Übergang von*** `I` ***oder*** `B` ***zu*** `B` *(neuer Chunk)* ***oder*** `O` *(Outside)*

Chunking als *supervised*-Sequenzklassifikation

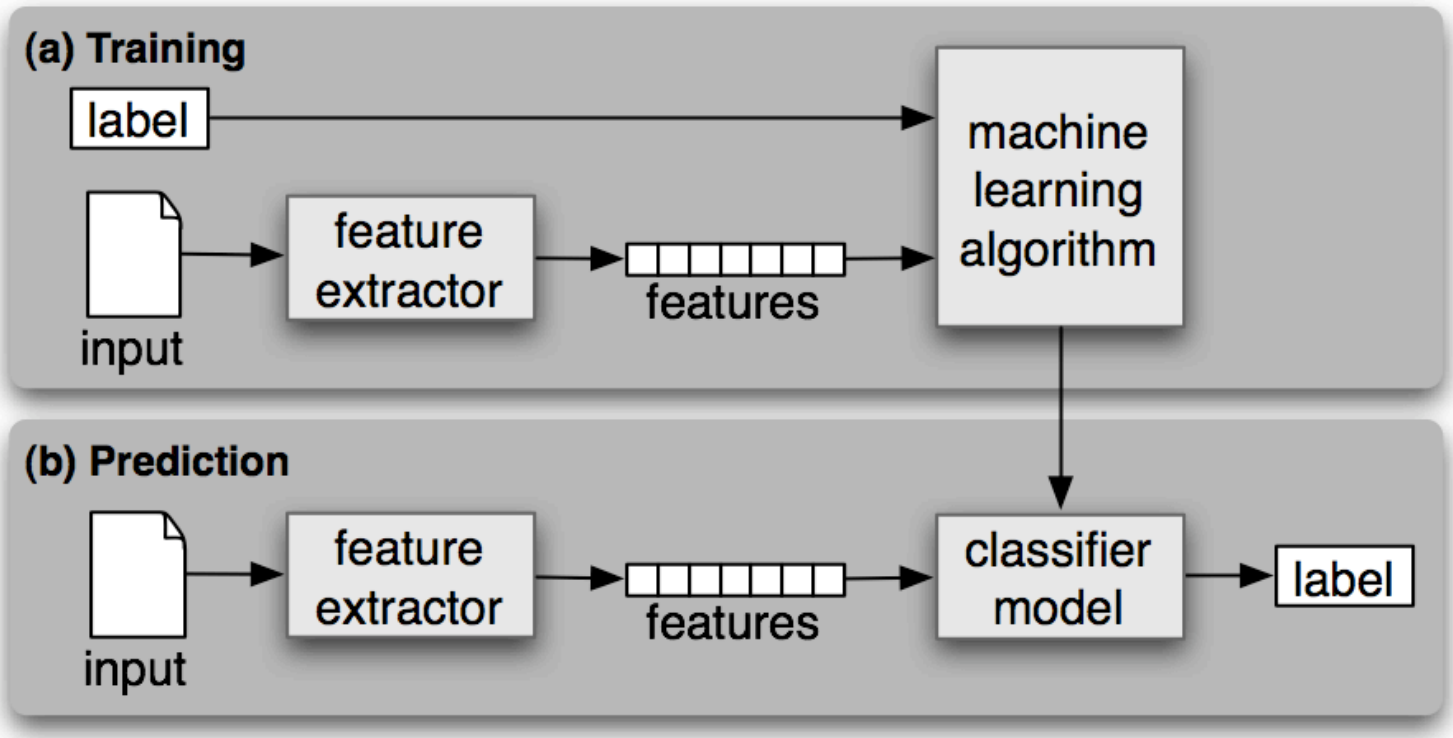

Abbildung: Schema *supervised*-Klassifikation (http://www.nltk.org/images/supervised-classification.png)

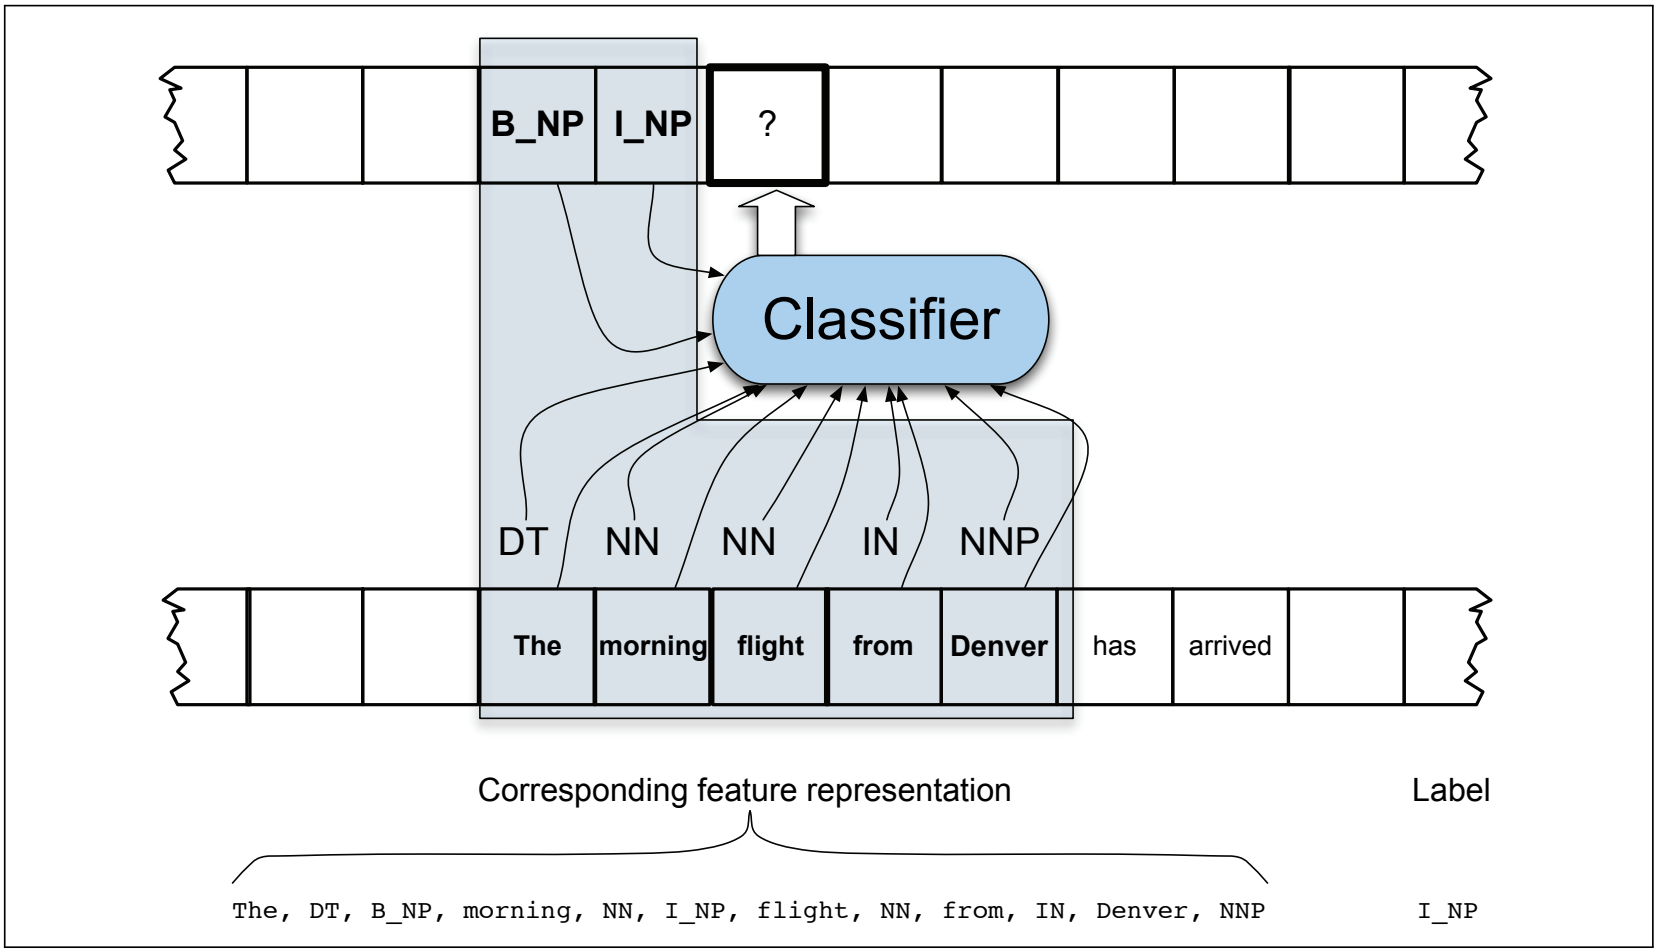

Abbildung: Chunking als Sequenzklassifikation (momentaner Zustand: Tagging von *flight*); Input wird durch eine aus Kontextfenster extrahierte Feature-Menge repräsentiert (Abbildung nach: Speech and Language Processing. Daniel Jurafsky & James H. Martin. Draft of August 28, 2017, Figure 12.8, p. 12, https://web.stanford.edu/~jurafsky/slp3/12.pdf)